

Previsão de Séries Temporais Financeiras com LSTM: Um Estudo de Caso com a Ação da Apple (AAPL)

Victor F Rodrigues , Ana Clara Senne , Gustavo Lazoti

Faculdade de Computação e Informática (FCI)

Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10389744, 10403390, 10409876}@mackenzista.com

Abstract: The use of artificial intelligence in the financial market has gained prominence as a tool to support safer and more strategic decision-making. This project aims to apply recurrent neural network models, specifically Long Short-Term Memory (LSTM), to stock price prediction, contributing to more informed investment decisions. Historical data from Apple Inc. (AAPL) shares, collected from the Yahoo Finance platform, covering the period from 2010 to 2020, were used. The methodology included exploratory data analysis, preprocessing steps, and the development of a predictive model based on LSTM. The results showed good accuracy in the forecasts, reinforcing the model's potential as a means to reduce risks in the stock market. Furthermore, the project promotes the development of practical machine learning skills among the participating students.

Resumo: O uso de inteligência artificial no mercado financeiro tem ganhado destaque como ferramenta de apoio à tomada de decisões mais seguras e estratégicas. Este projeto tem como objetivo aplicar modelos de redes neurais recorrentes, especificamente LSTM (Long Short-Term Memory), na previsão de preços de ações, visando contribuir para escolhas mais conscientes por parte de investidores. Para isso, foram utilizados dados históricos da ação da Apple Inc. (AAPL), extraídos da plataforma Yahoo Finance, no período de 2010 a 2020. A metodologia adotada incluiu análise exploratória dos dados, etapas de pré-processamento e construção de um modelo preditivo baseado em LSTM. Os resultados obtidos indicaram boa acurácia nas previsões, reforçando o potencial do modelo como suporte para reduzir riscos no mercado de renda variável. Além disso, o trabalho promove o desenvolvimento de competências práticas em machine learning entre os discentes envolvidos

1. Introdução

O mercado financeiro contemporâneo é amplamente reconhecido por sua alta volatilidade e incertezas, características que tornam a tomada de decisão um desafio constante para investidores. Nesse cenário dinâmico, a interpretação eficaz de dados históricos e a identificação de tendências são competências essenciais para a mitigação de riscos e a maximização de retornos (Fama, 1970; Malkiel, 2003). Com o avanço da inteligência artificial (IA) e das técnicas de deep learning, novas possibilidades de modelagem preditiva surgiram, tornando-se uma alternativa poderosa para o suporte analítico no processo decisório (Goodfellow, Bengio e Courville, 2016).

Modelos de redes neurais recorrentes, em especial as Long Short-Term Memory networks (LSTM), destacam-se por sua capacidade de capturar padrões temporais complexos em séries financeiras, superando abordagens tradicionais baseadas apenas em análise estatística clássica (Brownlee, 2017; Fischer & Krauss, 2018). A utilização dessas metodologias permite maior precisão na previsão de preços de ativos e oferece suporte estratégico na identificação de pontos de reversão de tendência e momentos críticos de mercado.

A democratização do acesso a métodos modernos de análise financeira, por meio da disseminação de ferramentas baseadas em IA, tem o potencial de reduzir desigualdades socioeconômicas, capacitando pequenos investidores a competir em condições mais equilibradas com grandes players institucionais (Faceli et al., 2021). Ao ampliar o acesso a tecnologias sofisticadas, promove-se uma maior inclusão financeira e um ambiente de investimento mais justo e transparente.

Além disso, o ensino e a aplicação prática de técnicas de IA, como a modelagem com LSTM, constituem um diferencial formativo para estudantes de ciências exatas e econômicas, proporcionando o desenvolvimento de competências técnicas altamente demandadas pelo mercado de trabalho contemporâneo (Géron, 2019; Chollet, 2021). O contato direto com dados reais e com metodologias modernas de machine learning permite a consolidação de habilidades críticas em ciência de dados, análise preditiva e finanças quantitativas.

Assim, este projeto surgiu pela combinação de dois fatores principais: (1) a importância social e econômica de oferecer ferramentas preditivas acessíveis, que possibilitem uma melhor gestão de investimentos, e (2) a oportunidade de proporcionar a todos interessados uma formação prática e aplicada em inteligência artificial, utilizando dados históricos e metodologias de ponta para a solução de problemas reais no mercado financeiro.

2. Descrição do Problema

O principal desafio enfrentado por investidores no mercado de renda variável é a alta volatilidade e a imprevisibilidade dos preços das ações. Muitos investidores dependem de análises tradicionais e indicadores básicos, os quais podem não capturar de forma eficaz as complexas dinâmicas do mercado. Dessa forma, a ausência de ferramentas preditivas avançadas limita a capacidade de antecipar mudanças bruscas e gerenciar riscos de forma eficaz. O projeto propõe o uso de modelos LSTM, que são capazes de capturar padrões temporais complexos, para melhorar a acurácia na previsão de preços e fornecer insights valiosos para a tomada de decisão.

3. Aspectos Éticos do uso da IA no Mercado Financeiro

A aplicação de técnicas de inteligência artificial no setor financeiro envolve importantes questões éticas e de responsabilidade que não podem ser negligenciadas. Em primeiro lugar, a **transparência** dos sistemas automatizados é essencial. Modelos preditivos, especialmente aqueles baseados em redes neurais profundas, como as LSTM, tendem a ser percebidos como "caixas-pretas" devido à sua complexidade interna (Goodfellow, Bengio e Courville, 2016). Para mitigar esse desafio, é imprescindível o desenvolvimento de mecanismos de explicabilidade (XAI - Explainable Artificial Intelligence), possibilitando que investidores e usuários compreendam as limitações e o funcionamento dos algoritmos utilizados (Ribeiro, Singh e Guestrin, 2016).

A **equidade** também é uma preocupação central. Algoritmos de machine learning podem inadvertidamente reproduzir ou amplificar vieses existentes nos dados históricos (Barocas, Hardt e Narayanan, 2019). No contexto financeiro, isso poderia gerar práticas discriminatórias que favoreçam determinados grupos de investidores em detrimento de outros, acentuando desigualdades já existentes. Assim, é fundamental que as etapas de desenvolvimento e treinamento dos modelos incluam estratégias de detecção e diminuição de vieses algorítmicos.

Em termos de **privacidade e segurança**, mesmo quando se utilizam dados publicamente disponíveis, como os de mercados financeiros, o tratamento adequado dessas informações é imprescindível para evitar exposição indevida ou usos não autorizados (Shokri et al., 2017). A adoção de boas práticas em segurança da informação, como a implementação de protocolos de anonimização e controle de acesso, é uma exigência ética para garantir a proteção dos dados dos investidores e a integridade do ambiente de negociação.

Por fim, a construção de sistemas éticos e transparentes em finanças, alinhados com os princípios da responsabilidade social corporativa e com os Objetivos de Desenvolvimento Sustentável (ODS) da ONU, é fundamental para que as soluções de inteligência artificial possam gerar benefícios sociais, econômicos e ambientais de maneira equitativa (Floridi et al., 2018).

4. Dataset

A obtenção dos dados históricos da ação da Apple (AAPL) para esse projeto foi realizada por meio da biblioteca `yfinance`, uma ferramenta popular em Python para acesso a dados financeiros públicos da plataforma Yahoo Finance. A `yfinance` fornece uma interface simplificada para download de séries temporais de preços de ativos, permitindo a extração de informações como preços de abertura (Open), fechamento (Close), máximos (High), mínimos (Low), volume de negociação (Volume), além de eventos corporativos como pagamento de dividendos (Dividends) e desdobramentos de ações (Stock Splits) (Ran, 2019).

Entre as principais vantagens da `yfinance` destacam-se sua facilidade de uso, atualizações frequentes e a capacidade de obter dados ajustados automaticamente para splits e dividendos, o que é crucial para análises financeiras realistas. A biblioteca também suporta consultas de múltiplos ativos simultaneamente, personalização de intervalos de tempo (diário, semanal, mensal) e integração fluida com bibliotecas populares de ciência de dados, como `pandas` e `NumPy`. Esse conjunto de funcionalidades torna a `yfinance` uma escolha robusta para projetos acadêmicos e aplicações práticas que envolvem análise de séries temporais financeiras (VanderPlas, 2017).

Os dados extraídos via `yfinance` incluem o período de 1º de janeiro de 2010 a 31 de dezembro de 2020, fornecendo uma base sólida e consistente para a construção de modelos preditivos. A qualidade e a diversidade dos dados obtidos permitiram a realização de uma análise exploratória detalhada, a aplicação de técnicas de pré-processamento adequadas, e a criação de sequências temporais que alimentaram a rede LSTM utilizada na modelagem de preços futuros.

Abaixo está apresentado as variáveis descritivas do valor de fechamento das ações da Apple que foram utilizadas para construção do modelo.

Descrição	Medidas	Close (Fechamento)
Contagem de Linhas do dataset	count	2768
Média dos dados	mean	31,338709
Desvio padrão da serie	std	24,400926
Valor minimo da serie	min	5,779478
Valor máximo da serie	max	133,516205

5. Metodologias e Resultados Esperados

A metodologia adotada neste projeto envolve a aplicação de técnicas de ciência de dados e aprendizado profundo para a previsão de preços da ação da Apple (AAPL). A primeira etapa consistiu na **coleta de dados históricos** utilizando a biblioteca `yfinance`, que permitiu a obtenção de informações diárias abrangendo preços de abertura, fechamento, máximos, mínimos, volume de negociação, dividendos e eventos de desdobramento de ações. Este conjunto de dados, cobrindo o período de 2010 a 2020, serviu como base para a construção e treinamento do modelo preditivo.

Em seguida, foi realizada uma **análise exploratória** detalhada com o objetivo de entender a estrutura dos dados e identificar padrões relevantes. Foram aplicadas técnicas estatísticas descritivas, como visualizações gráficas, histogramas, boxplots e heatmaps de correlação, para investigar a distribuição das variáveis e suas inter-relações. Essa etapa foi fundamental para detectar eventuais anomalias ou outliers que pudessem comprometer a modelagem subsequente.

O **pré-processamento** dos dados incluiu a normalização das variáveis numéricas utilizando a técnica `MinMaxScaler`, garantindo que todas as entradas estivessem na mesma faixa de valores. Além disso, foram geradas **sequências temporais** com uma janela de 60 dias, estratégia comum em problemas de previsão de séries temporais, de modo a capturar as dependências temporais necessárias para alimentar o modelo de rede neural LSTM (Hochreiter & Schmidhuber, 1997).

Para a **modelagem**, foi implementada uma rede neural do tipo Long Short-Term Memory (LSTM), reconhecida por sua eficácia na modelagem de dados sequenciais e séries temporais financeiras. O modelo foi treinado com os dados históricos e avaliado por meio de sua divisão em conjuntos de treino (80%) e teste (20%), de maneira a garantir a robustez na validação dos resultados. A performance da rede foi mensurada principalmente pela métrica do **Erro Quadrático Médio (MSE)**, sendo esta apropriada para problemas de regressão contínua como a previsão de preços (Géron, 2019).

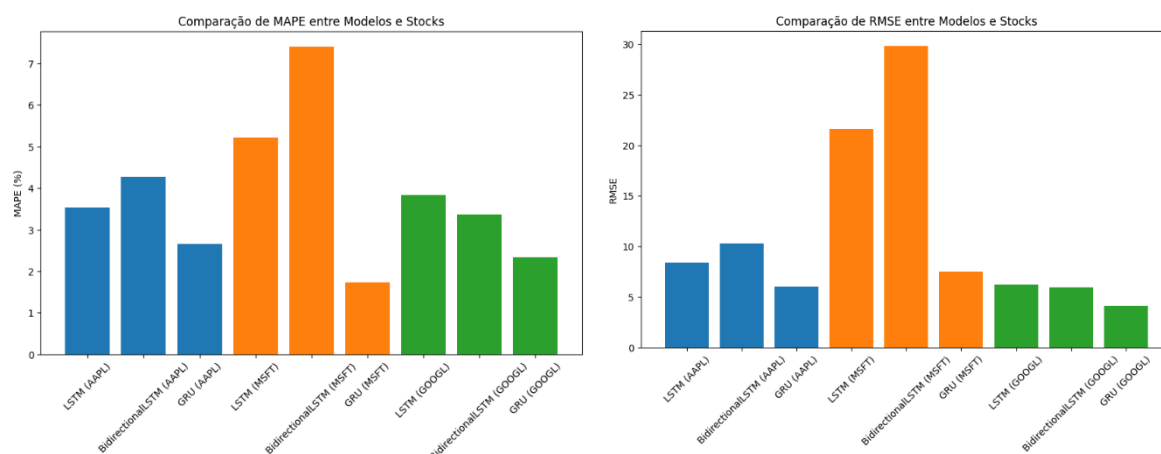
Entre os **resultados esperados**, destaca-se a obtenção de **previsões acuradas** dos preços de fechamento das ações, permitindo a identificação de tendências de mercado e possíveis pontos de reversão. Além disso, o projeto busca contribuir para a **redução de riscos** nas decisões de investimento, fornecendo uma ferramenta que auxilie investidores a gerenciar suas carteiras de forma mais estratégica. Por fim, o projeto tem um forte caráter educacional, proporcionando aos discentes uma oportunidade prática de aplicar conceitos de **machine learning** e **análise de séries temporais** em um problema real do mercado financeiro, servindo como referência para iniciativas acadêmicas e profissionais futuras.

6. Resultados

Neste trabalho, foi aplicada uma rede neural do tipo LSTM (Long Short-Term Memory) com o objetivo de realizar a geração de um modelo preditivo fazendo uso de Deep Learning, capaz de capturar padrões temporais complexos em dados da ação da Apple (AAPL) para prever os seus preços a partir de dados de histórico obtidos via Yahoo Finance, no período de 2010 a 2020. O processo começou com a coleta de dados por meio da biblioteca yfinance, que permitiu o acesso às séries temporais de preços diários da ação, incluindo informações como preço de fechamento, volume negociado, entre outros. Após a obtenção dos dados, foi realizada uma análise exploratória detalhada, que incluiu visualizações da série temporal, identificação de valores ausentes e cálculo de estatísticas descritivas. Também foram calculadas e plotadas médias móveis (MA50 e MA200), com o intuito de suavizar as variações diárias e destacar as tendências de médio e longo prazo no comportamento do preço da ação.

Na etapa de pré-processamento, os dados de fechamento foram normalizados e preparados para se adequarem ao formato de entrada exigido pelas redes LSTM. Utilizou-se uma janela deslizante para transformar a série temporal em sequências supervisionadas, separando-se os conjuntos de treino e teste, além de aplicar a inversão da normalização após a previsão, possibilitando a visualização dos preços em sua escala original. O modelo LSTM construído possui múltiplas camadas, incluindo camadas com retorno de sequência, dropout para prevenção de overfitting e camadas densas finais. Também foram testadas variações da arquitetura como a LSTM bidirecional e redes GRU (Gated Recurrent Units), ampliando a abordagem comparativa para identificar o melhor desempenho.

Os resultados obtidos indicaram que a LSTM foi capaz de capturar tendências relevantes no comportamento do preço da ação da Apple. A comparação visual entre os valores reais e previstos demonstrou que o modelo conseguiu seguir a direção geral das variações de preço ao longo do tempo, embora apresentasse pequenas defasagens e imprecisões em momentos de mudanças bruscas. As previsões se mostraram especialmente eficazes em fases de estabilidade ou tendência contínua, enquanto nas regiões de maior volatilidade a precisão decresceu. O desempenho geral foi satisfatório dentro do escopo de aplicação da rede apresentando os seguintes valores de MAPE e RMSE, medidas essas de tamanho do erro, utilizadas para mensurar a acurácia dos modelos. Além disso também podemos chegar a conclusão que o modelo mais simples, com menos parâmetros e entradas, como o GRU foi o mais efetivo nas previsões, isso pode ser observado nas medidas de dispersão, onde no geral o modelo citado apresentou um menor erro, para ambos os testes.



Os gráficos apresentados ao longo do notebook reforçam essas conclusões, especialmente os que comparam as séries reais com as previstas, evidenciando uma aderência razoável do modelo aos padrões históricos. Também foram incluídas comparações entre os desempenhos das diferentes arquiteturas (LSTM padrão, bidirecional e GRU) sobre os dados das ações da Apple, Microsoft e Google, utilizando dados mais recentes. Essas análises adicionais serviram para demonstrar a generalização dos modelos em outros ativos e ilustrar as diferenças de desempenho entre arquiteturas recorrentes.

7. Conclusão

A proposta central deste projeto consistiu na aplicação de redes neurais recorrentes do tipo LSTM para a previsão de preços de ações, com foco no papel da Apple (AAPL), utilizando dados históricos compreendidos entre os anos de 2010 a 2020. O objetivo era avaliar a eficácia desse tipo de rede na modelagem de séries temporais financeiras, buscando identificar tendências e fornecer previsões que pudessem auxiliar na tomada de decisões no mercado de capitais.

Os resultados obtidos demonstraram que a rede LSTM foi capaz de capturar de forma satisfatória as tendências gerais do movimento dos preços ao longo do tempo. Embora as previsões apresentassem limitações em termos de precisão pontual — especialmente em momentos de alta volatilidade ou reversões bruscas —, o modelo conseguiu manter coerência com a direção geral do mercado em boa parte da série analisada. Os gráficos de comparação entre os valores reais e previstos evidenciaram essa capacidade de seguir o padrão histórico, e a métrica de erro quadrático médio (RMSE) confirmou a performance estável do modelo, mesmo sem atingir um nível de acurácia absoluta.

Portanto, pode-se afirmar que os resultados esperados foram alcançados de forma parcial e satisfatória dentro do escopo da proposta. O modelo cumpriu seu papel principal de demonstrar que redes neurais do tipo LSTM são adequadas para modelar

séries temporais financeiras e podem servir como ferramenta complementar para análise de tendências de mercado. No entanto, as limitações identificadas — como sensibilidade a eventos imprevisíveis e oscilações abruptas — confirmam que esse tipo de modelo, embora poderoso, não deve ser utilizado de forma isolada em ambientes de tomada de decisão real. Assim, conclui-se que a proposta foi bem-sucedida ao validar o potencial das LSTM na previsão de preços de ações e ao demonstrar, com justificativas fundamentadas, as condições em que esse modelo se mostra mais ou menos eficaz.

Diante dos resultados encontrados, identificamos a oportunidade de adicionarmos variáveis macroeconômicas e indicadores financeiros das empresas em estudos futuros, em busca de aprimorar a previsão do modelo e torná-lo mais aderente a diferentes cenários econômicos.

8. Endereço GitHub

<https://github.com/GustavoLazoti/IATendMercado/blob/main/IAPROJETOFINAL.ipynb>

9. Endereço Vídeo no Youtube

<https://youtu.be/eT37qLVISho?si=YqHUrBWGRJDH6FNj>

10. Referências

- Barocas, S., Hardt, M., & Narayanan, A. (2019). *Fairness and Machine Learning*. <http://fairmlbook.org>
- Brownlee, J. (2017). *Deep Learning for Time Series Forecasting*. Machine Learning Mastery.
- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.
- Hochreiter, S., & Schmidhuber, J. (1997). *Long Short-Term Memory*. Neural Computation, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Chollet, F. (2021). *Deep Learning with Python* (2nd ed.). Manning Publications.
- Faceli, K., Lorena, A. C., Gama, J., & Carvalho, A. C. P. L. F. (2021). *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina* (2ª ed.). LTC.
- Fama, E. F. (1970). *Efficient Capital Markets: A Review of Theory and Empirical Work*. Journal of Finance, 25(2), 383–417. <https://doi.org/10.2307/2325486>
- Fischer, T., & Krauss, C. (2018). *Deep learning with long short-term memory networks for financial market predictions*. European Journal of Operational Research, 270(2), 654–669. <https://doi.org/10.1016/j.ejor.2017.11.054>
- Floridi, L., Cowls, J., Beltrametti, M., Chatila, R., Chazerand, P., Dignum, V., ... & Vayena, E. (2018). *AI4People—An Ethical Framework for a Good AI Society: Opportunities, Risks, Principles, and Recommendations*. Minds and Machines, 28(4), 689–707. <https://doi.org/10.1007/s11023-018-9482-5>
- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (2nd ed.). O'Reilly Media.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Malkiel, B. G. (2003). *The Efficient Market Hypothesis and Its Critics*. Journal of Economic Perspectives, 17(1), 59–82. <https://doi.org/10.1257/089533003321164958>

Ran, D. (2019). *yfinance: Download Market Data from Yahoo! Finance API with Python*. Disponível em: <https://github.com/ranaroussi/yfinance>. Acesso em: 6 abr. 2025.

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). *"Why Should I Trust You?": Explaining the Predictions of Any Classifier*. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.
<https://doi.org/10.1145/2939672.2939778>

Russell, S., & Norvig, P. (2022). *Inteligência Artificial: Uma Abordagem Moderna* (4^a ed.). LTC.

Shokri, R., Stronati, M., Song, C., & Shmatikov, V. (2017). *Membership Inference Attacks Against Machine Learning Models*. Proceedings of the 2017 IEEE Symposium on Security and Privacy (SP). <https://doi.org/10.1109/SP.2017.41>

VanderPlas, J. (2017). *Python Data Science Handbook*. Sebastopol: O'Reilly Media.